

Автоматическое построение нейросети оптимальной сложности

Горян¹ Н. А. Бахтеев¹ О. Ю. Стрижов² В. В.

goryan.na@phystech.edu; bakhteev@phystech.edu; strijov@phystech.edu

¹Московский физико-технический институт

²Вычислительный центр им. А. А. Дородницына ФИЦ ИУ РАН

Работа посвящена выбору оптимальной модели нейронной сети. Нейронная сеть рассматривается как вычислительный граф, рёбра которого — примитивные функции, а вершины — промежуточные представления выборки. Предполагается, что структуру нейронной сети можно упростить без значимой потери качества классификации. Структура нейросети определяется вершинами симплекса. Для определения нужной структуры нейронной сети предлагается проводить оптимизацию гиперпараметров и структурных параметров. Для решения задачи оптимизации предлагается проводить релаксацию структуры. Для анализа качества представленного алгоритма проводятся эксперименты на выборках Boston, MNIST и CIFAR-10.

Ключевые слова: *нейронные сети, оптимизация гиперпараметров, прореживание нейронной сети, оптимальная структура нейронной сети, вариационный вывод.*

Введение

В последнее время нейронные сети стали очень широко использоваться в различных прикладных задачах. При выборе нейросети часто возникает вопрос как правильно выбрать гиперпараметры. Одной из основных областей применения являются мобильные устройства, которые в силу своих ограниченных вычислительных ресурсов не могут справляться с избыточно сложными неросетями.

В данной работе рассматривается метод построения оптимальной нейронной сети. Существует много способов построения нейронных сетей. Для того, чтобы подобрать нужную сеть требуется узнать её гиперпараметры [1]: количество слоёв, нейронов в каждом слое и функции активации каждого нейрона. Подбор этих гиперпараметров является вычислительно сложной задачей [2].

Существует несколько подходов построения оптимальной сети. В работах [3, 4] используется метод прореживания нейросети. Он заключается в том, что строится заведомо переусложнённая модель, которая в последствии упрощается. Ещё одним способом, предложенным в работе [5], является метаобучение, которое получая на вход некоторую выборку возвращает оптимальные гиперпараметры. В данной работе исследуется метод, который оптимизирует параметры и гиперпараметры нейросети в единой процедуре. В основе метода лежит алгоритм DARTS, предложенным в работе [6]. В его основе лежит процедура релаксации: переход от дискретного множества гиперпараметров к непрерывному, что позволяет использовать методы оптимизации для нахождения лучших гиперпараметров. Входными данными метода являются некоторый набор данных и заранее определённый набор функций активации. Как результат мы получаем оптимальную нейросеть.

Проверка и анализ метода проводится на выборке Boston Housing [7], MNIST [8], CIFAR-10 [9] и синтетических данных. Результат сравнивается с моделями, полученными при помощи базовых алгоритмов.

Литература

- [1] In Jae Myung and Mark A. Pitt. Applying occam's razor in modeling cognition: A bayesian approach. *Psychonomic Bulletin & Review*, 4(1):79–95, Mar 1997.
- [2] I. Sutskever, O. Vinyals, and Q. Le. Sequence to sequence learning with neural networks. In *Advances in Neural Information Processing Systems 27*, volume 2 of *28th Annual Conference on Neural Information Processing Systems*, pages 3104–3112, Montreal, Quebec, Canada, 08–13 December 2014. Curran Associates, Inc.
- [3] Y. LeCun, J. Denker, and S. Solla. Optimal brain damage. In *Advances in Neural Information Processing Systems 2*, pages 598–605, Denver, Colorado, USA, 27–30 November 1989. Morgan-Kaufmann.
- [4] A. Graves. Practical variational inference for neural networks. In *Advances in Neural Information Processing Systems 24*, 25th Annual Conference on Neural Information Processing Systems, pages 2348–2356, Granada, Spain, 12–14 December 2011. Curran Associates, Inc.
- [5] Dougal Maclaurin, David Duvenaud, and Ryan P. Adams. Gradient-based hyperparameter optimization through reversible learning. In *Proceedings of the 32Nd International Conference on International Conference on Machine Learning - Volume 37*, ICML'15, pages 2113–2122. JMLR.org, 2015.
- [6] Hanxiao Liu, Karen Simonyan, and Yiming Yang. Darts: Differentiable architecture search, 2018. cite arxiv:1806.09055.
- [7] D. Harrison and D. Rubinfeld. Hedonic prices and the demand for clean air, 1978. <https://www.cs.toronto.edu/~delve/data/boston/bostonDetail.html>.
- [8] Y. LeCun, C. Cortes, and C. J.C. Burges. The mnist datadase of handwritten digits, 1998. <http://yann.lecun.com/exdb/mnist/>.
- [9] A. Krizhevsky, V. Nair, and G. Hinton. The cifar-10 dataset, 2009. <http://www.cs.toronto.edu/~kriz/cifar.html>.
- [10] C. Bishop. *Pattern Recognition and Machine Learning*. Springer, Berlin, Heidelberg, 2006.