

Автоматическое построение нейросети оптимальной сложности

Горян¹ Н. А. Бахтеев¹ О. Ю. Стрижов² В. В.

goryan.na@phystech.edu; bakhteev@phystech.edu; strijov@phystech.edu

¹Московский физико-технический институт

²Вычислительный центр им. А. А. Дородницына ФИЦ ИУ РАН

Работа посвящена выбору оптимальной модели нейронной сети. Нейронная сеть рассматривается как вычислительный граф, рёбра которого — примитивные функции, а вершины — промежуточные представления выборки. Предполагается, что структуру нейронной сети можно упростить без значимой потери качества классификации. Структура нейросети определяется вершинами симплекса. Для определения нужной структуры нейронной сети предлагается проводить оптимизацию гиперпараметров и структурных параметров. Для решения задачи оптимизации предлагается проводить релаксацию структуры. Для анализа качества представленного алгоритма проводятся эксперименты на выборках Boston, MNIST и CIFAR-10.

Ключевые слова: *нейронные сети, оптимизация гиперпараметров, прореживание нейронной сети, оптимальная структура нейронной сети, вариационный вывод.*

Введение

В данной работе рассматривается метод построения оптимальной нейронной сети. В общем, проблема нахождения такой сети для определённых данных является очень ресурсоёмкой процедурой. Но в силу того, что количество портативных устройств с ограниченными по производительности ресурсами растёт всё быстрее, эта проблема является очень актуальной, поскольку её решение позволит использовать методы машинного обучения на этих устройствах.

Существует много способов построения нейронных сетей для различных сфер деятельности. Известно очень мало эффективных способов построения оптимальных нейросетей. Для того, чтобы подобрать нужную сеть требуется узнать её гиперпараметры [1]: количество слоёв, нейронов в каждом слое и функции активации каждого нейрона. Подбор этих гиперпараметров является вычислительно сложной задачей [2].

Существует несколько подходов построения оптимальной сети. В работах [3, 4] используется метод прореживания нейросети. Он заключается в том, что строится заведомо переусложнённая модель, которая в последствии упрощается. Ещё одним способом, предложенным в работе [5], является метаобучение. В его основе лежит идея того, что заранее обученная нейронная сеть строит по входным данным требуемую нейросеть.

Данная работа посвящена методу построения оптимальной нейронной сети подбором гиперпараметров в одной процедуре. В основе метода лежит алгоритм DARTS, предложенным в работе [6]. Входными данными метода являются некоторый набор данных и заранее определённый набор функций активации. Как результат мы получаем оптимальную нейросеть.

Проверка и анализ метода проводится на выборке Boston Housing [7], MNIST [8], CIFAR-10 [9] и синтетических данных. Результат сравнивается с моделями, полученными при помощи базовых алгоритмов.

Литература

- [1] In Jae Myung and Mark A. Pitt. Applying occam's razor in modeling cognition: A bayesian approach. *Psychonomic Bulletin & Review*, 4(1):79–95, Mar 1997.
- [2] I. Sutskever, O. Vinyals, and Q. Le. Sequence to sequence learning with neural networks. In *Advances in Neural Information Processing Systems 27*, volume 2 of *28th Annual Conference on Neural Information Processing Systems*, pages 3104–3112, Montreal, Quebec, Canada, 08–13 December 2014. Curran Associates, Inc.
- [3] Y. LeCun, J. Denker, and S. Solla. Optimal brain damage. In *Advances in Neural Information Processing Systems 2*, pages 598–605, Denver, Colorado, USA, 27–30 November 1989. Morgan-Kaufmann.
- [4] A. Graves. Practical variational inference for neural networks. In *Advances in Neural Information Processing Systems 24*, 25th Annual Conference on Neural Information Processing Systems, pages 2348–2356, Granada, Spain, 12–14 December 2011. Curran Associates, Inc.
- [5] Dougal Maclaurin, David Duvenaud, and Ryan P. Adams. Gradient-based hyperparameter optimization through reversible learning. In *Proceedings of the 32Nd International Conference on International Conference on Machine Learning - Volume 37*, ICML'15, pages 2113–2122. JMLR.org, 2015.
- [6] Hanxiao Liu, Karen Simonyan, and Yiming Yang. Darts: Differentiable architecture search, 2018. cite arxiv:1806.09055.
- [7] D. Harrison and D. Rubinfeld. Hedonic prices and the demand for clean air, 1978. <https://www.cs.toronto.edu/~delve/data/boston/bostonDetail.html>.
- [8] Y. LeCun, C. Cortes, and C. J.C. Burges. The mnist datadase of handwritten digits, 1998. <http://yann.lecun.com/exdb/mnist/>.
- [9] A. Krizhevsky, V. Nair, and G. Hinton. The cifar-10 dataset, 2009. <http://www.cs.toronto.edu/~kriz/cifar.html>.
- [10] C. Bishop. *Pattern Recognition and Machine Learning*. Springer, Berlin, Heidelberg, 2006.